

Tutoriale podstawowe (Python etc.)

Kurs Pythona na BIT Python

- prowadzony od zera do dość zaawansowanych kwestii
- są wszystkie prezentacje, nagrania wykładów, zadania i rozwiązania

Kurs Numpy + Pandas na BIT Python

- od zera, do dość szczegółowych kwestii
- oparty na bardzo dobrej książce "Data Science Handbook" J. VanderPlas'a, twórcy Pandasa

Python Numpy Tutorial (with Jupyter and Colab)

- szybka powtórka od Stanfordu z Pythona i Numpy'a
- same podstawy, ale jak ktoś całkiem nie zna tematu, to dobry punkt wyjścia

Getting Started With Jupyter Notebook for Python

- tutorial jak obsługiwać Jupyter Notebooka
- krótkie i same podstawy - tyle, ile nam trzeba

100 Numpy exercises

- zbiór zadań z Numpy'a, z rozwiązaniami
- od prostych do ekstremalnie trudnych, ogółem wszystkie są tricky
- można się nauczyć dużo różnych sztuczek

Pandas exercises

- zbiór mocno praktycznych i dość otwartych zadań z Pandasa
- na prawdziwych zbiorach, dobrze ćwiczy ogólną analizę danych
- nie na start, ale doskonale do nauki w praktyce

Ogółem machine learning

MLU-Explain: Train, Test, and Validation Sets

- krótkie, interaktywne i przystępne omówienie, po co nam podział na podzbiory

MLU-Explain: Bias-Variance Tradeoff

- interaktywne i przystępne omówienie bias-variance tradeoff
- przykład 2 nowych algorytmów (k najbliższych sąsiadów, regresja LOESS)

Understanding the Bias-Variance Tradeoff

- bardziej szczegółowe i dłuższe omówienie bias-variance tradeoff
- omówione sposoby na radzenie sobie z tym, w tym takie, które zmniejszają jedno źródło błędu bez zwiększania drugiego

Regresja liniowa

MLU-Explain: Linear Regression

- krótkie, interaktywne i przystępne omówienie regresji liniowej
- pod koniec trochę dodatkowych szczegółów dla pogłębienia wiedzy

Kanał Steve Brunton na YT

- [Linear regression](#)
- [Least Squares Regression and the SVD](#)
- wytłumaczone krok po kroku, wyprowadzając każdy wzór
- doskonale na początek
- polecam cały kanał, doskonała matematyka stosowana

Derivation of simple linear regression formula

- wyprowadzenie wzorów prostej regresji liniowej (z 1 zmienną)
- dobre na początek, jeżeli ktoś nie czuje się komfortowo z wyprowadzeniami na wektorach i macierzach

Understanding Linear Regression using the Singular Value Decomposition

- omówienie zastosowania SVD do regresji liniowej
- ładne obrazki i zwarte wzory

Kurs Andrew Ng

- [Coursera](#) - bez certyfikatu za darmo AFAIK
- [YouTube](#) - gorsza jakość, ale zawartość chyba dokładnie ta sama
- najbardziej znany kurs ML na świecie, pierwszy kurs Coursery, dla niego powstała ta platforma
- uwaga: zadania do kursu kiedyś były w MATLABie, ale teraz są już w Pythonie

Dive Into Deep Learning - Linear Regression

- bardzo szczegółowe, solidne matematycznie omówienie regresji liniowej, szczególnie w kontekście sieci neuronowych
- funkcja kosztu, naiwne rozwiązanie analityczne (nieużywane w praktyce, używamy SVD!), szczegółowo opisane rozwiązanie z minimalizacją funkcji kosztu
- podana implementacja w 3 frameworkach do deep learningu (PyTorch - polecam, TensorFlow, MXNet)

Multivariate Linear Regression from Scratch in Python

- wyjaśnienie i implementacja od zera regresji liniowej wielokrotnej dla wielu zmiennych
- używa metody z pochodną, typowe w sieciach neuronowych

Statistics By Jim

- [The Difference between Linear and Nonlinear Regression Models](#)
- [How to Choose Between Linear and Nonlinear Regression](#)
- [Curve Fitting using Linear and Nonlinear Regression](#)
- bardzo dobra strona, prowadzona przez statystyka, dużo materiałów o regresji, w tym o modelach nieliniowych

Interpretable Machine Learning - Linear Regression

- analiza regresji liniowej pod względem interpretowalności (wytlumaczalności) modelu
- rozdział z bardzo dobrej książki o interpretowalnym ML, polecam całość - jest darmowa i dostępna pod tym linkiem

7 Classical Assumptions of Ordinary Least Squares (OLS) Linear Regression

- szczególnie ważny artykuł ze Statistics By Jim
- regresja liniowa ma dużo założeń, nie tylko kombinację liniową, dlatego ma duży bias
- artykuł intuicyjnie (nie szczegółowo matematycznie) opisuje wszystkie te założenia
- uwaga - nie zawsze w praktyce trzeba je spełniać, liczy się przede wszystkim generalizacja modelu, ale warto wtedy wiedzieć, jakie założenia się ignoruje :)

Why is the bias term not regularized in ridge regression?

- wyrazu wolnego (bias), czyli punktu przecięcia z osiami układu współrzędnych, nie regularyzujemy w regresji L1 i L2
- krótkie wyjaśnienie czemu

Coordinate Descent

- omówienie algorytmu optymalizacji Coordinate Descent (CD) do optymalizacji funkcji nieróżniczkowalnych
- używany standardowo jako solver przy regularyzacji L1

Blog Xavier Bourret Sicotte

- [Ridge regression and L2 regularization - Introduction](#)
- [Animations of gradient descent: Ridge regression](#)
- [Ridge and Lasso: visualizing the optimal solutions](#)
- [Coordinate descent soft-thresholding update operator for LASSO](#)
- [Coordinate Descent - Implementation for linear regression](#)
- [Lasso regression: derivation of the coordinate descent update rule](#)
- [Lasso regression: implementation of coordinate descent](#)
- wyprowadzenia krok po kroku, świetne wizualizacje i kod w Pythonie dla regresji regularyzowanej
- szczególnie dobrze omawia algorytm Coordinate Descent (CD) dla optymalizacji nieróżniczkowalnej regresji LASSO (regularyzacja L1)

Regularization: Ridge Regression and the LASSO

- bardzo szczegółowa prezentacja o regularyzacji na przykładzie regresji z regularyzacją L2 i L1
- omawia także interpretację z perspektywy statystyki bayesowskiej
- szczegółowe omówienie praktycznych sposobów na dobór hiperparametrów oraz wykresów do analizy modeli

Stochastic Optimization Methods

- omówienie solverów do optymalizacji stochastycznej (krok po kroku, numerycznej) SAG oraz SAGA
- solverzy dla regresji ElasticNet
- i regresja liniowa, i logistyczna

Regresja logistyczna

[MLU-Explain: Logistic Regression](#)

- krótko, zwięźle i interaktywnie omówiony algorytm

[Logistic regression - Stanford](#)

- wprowadzenie gradient descent dla regresji logistycznej
- bardzo nietypowo maksymalizuje log likelihood zamiast minimalizować negative log likelihood (ale to tylko kwestia zmiany znaku)

Interpretable Machine Learning

- [Logistic regression](#)
- [Logistic regression and regularization](#)
- analiza regresji logistycznej pod względem interpretowalności (wyłumaczalności) modelu, w tym w wersji zregularyzowanej
- w przeciwieństwie do wielu (kiepskich) źródeł nie mówi po prostu "regresja logistyczna jest super prosta i interpretowalna", tylko omawia też wady tego modelu

[Logistic Regression Isn't Interpretable](#)

- krótki rant o tym, że regresja logistyczna wcale nie jest interpretowalna
- mało formalne i dość emocjonalne, ale całkiem słuszne w przekazie
- warto przeczytać po analizie rozdziału z "Interpretable Machine Learning"

[Logistic regression Python solvers' definitions](#)

- krótkie i zwięźle omówienie różnych solverów dla regresji logistycznej
- podane wady, zalety i use case'y poszczególnych solverów